

碩士論文口試

逐字稿

雙模態骨架與視覺特徵融合 於弱監督暴力偵測 多種骨幹網路之比較研究 Dual-Modal Skeleton-Visual Fusion for Weakly Supervised Violence Detection

研究生 鄭暉瀚 Wei-Han Jeng

指導教授 楊傳凱 博士

國立臺灣科技大學 資訊管理系

口試日期 2026 年 7 月 21 日

內容：正式簡報投影片 1-24 (建議時間約 22 分鐘)

附錄：口試追問備援投影片 25-31

文字來源：原始 PowerPoint 講者備註

雙模態骨架與視覺特徵融合 於弱監督暴力偵測 多種骨幹網路之比較研究 Dual-Modal Skeleton-Visual Fusion for Weakly Supervised Violence Detection

建議時間：20 秒

逐字講稿

各位口試委員、老師好，我是鄭暉瀚。今天要報告的題目是「雙模態骨架與視覺特徵融合於弱監督暴力偵測：多種骨幹網路之比較研究」。這項研究關注的是：當訓練資料只有影片層級標籤、沒有逐影格標註時，我們能不能同時利用畫面語意與人體動作結構，讓模型更準確地找出暴力事件；以及這個方法換到不同視覺骨幹、不同資料集與受污染影像後，是否仍然成立。接下來我會依序說明研究動機、方法、實驗結果、穩健性分析與研究限制。

監視影像的困難，不只是「看見暴力」

建議時間：45 秒

逐字講稿

監視影片通常很長，而且絕大多數時間都是正常的；真正需要注意的暴力事件可能只占其中幾秒。實務系統不能只回答「這部影片有沒有異常」，還要指出事件大概發生在哪個時間點。

逐影格標註事件起訖的成本很高；但若只給整部影片正常或異常標籤，模型又容易把背景或偶然物件當成捷徑。因此，本研究採用弱監督影片異常偵測：用影片層級標籤訓練，輸出細到片段或影格層級。

弱監督設定：只有影片標籤，卻要找出事件位置

建議時間：45 秒

逐字講稿

（時間不足可略過本頁）這張圖說明弱監督設定。左邊影片被切成多個片段；訓練時只知道整部影片被標為異常，不知道真正事件位於哪些片段。中間以多重實例學習把影片視為片段集合，讓高分片段支持影片層級判斷；右邊則輸出時間序列異常分數。

影片層級標籤與影格層級答案之間有資訊落差，因此方法必須同時處理特徵來源，以及片段分數如何聚合。

單一視覺線索容易誤判；動作結構提供互補證據

建議時間：40 秒

逐字講稿

視覺特徵擅長理解場景、物體與語意脈絡，但容易受到背景、遮擋與拍攝視角影響。骨架特徵聚焦人體關節與動作結構，對衣著、顏色或部分背景變化較不敏感；但人物太小、遮擋嚴重或姿態估計失敗時也會不可靠。

因此兩者各有優勢與盲點。本研究的核心假設是：不要固定平均兩種特徵，而要讓模型依片段判斷此刻更相信哪一種證據。

三個研究問題，對應三層驗證

建議時間：70 秒

逐字講稿

本研究整理成三個問題。第一，雙模態融合是否真的帶來價值？我不只比較融合與單模態，也比較簡單的晚期分數融合與可學習的門控融合，確認增益來自哪裡。第二，這個結論是否依賴某一個視覺骨幹？因此我選擇四個不同規模與訓練方式的視覺語言模型，並在 UCF-Crime 與 XD-Violence 兩個資料集重複驗證。第三，部署時影像可能受到雜訊、模糊或壓縮。現有測試時適應方法多半建立在 BatchNorm，而本研究骨幹主要使用 LayerNorm，所以我要確認 TENT 與 SAR 是否仍有效，並提出不更新模型參數的可靠度重加權策略。

也就是說，三個問題分別回答方法價值、泛化邊界與部署穩健性。

本研究四項貢獻

建議時間：30 秒

逐字講稿

這張以四個標題帶過：第一，建立視覺與骨架雙模態門控架構。第二，在相同下游框架比較四個視覺語言骨幹。第三，檢驗 TENT 與 SAR 在 LayerNorm 架構下的限制。第四，提出無梯度穩健化：以視覺串流 solo 分數離散度偵測判別力崩潰，配合骨架位移安全閘，測試時重新分配模態信任，而且不更新參數、不使用標籤。

從單一路徑，到多模態與測試時穩健化

建議時間：40 秒

逐字講稿

相關工作從光流、軌跡等手工特徵，演進到 3D CNN、雙串流網路與弱監督 MIL。近年視覺語言模型提供更強語意表徵，但多數研究仍以單一視覺串流為主；測試時適應則常以熵最小化更新正規化參數，許多機制依賴 BatchNorm。

本研究位於弱監督、多模態與 LayerNorm TTA 的交叉點：前半段研究視覺與骨架如何融合，後半段檢驗分布偏移下的適應方法。

整體架構：雙流特徵、門控融合、MIL 分數

建議時間：85 秒

逐字講稿

這是整體架構。首先把影片切成固定長度的片段，上方視覺串流以約一 FPS 抽取影格，再由凍結的視覺語言模型編碼並做 mean 加 max pooling；下方骨架串流先用 RTMPose 擷取關節，再由凍結的 CTR-GCN 把關節在空間與時間上的關係編成二百五十六維動作特徵。兩路特徵投影到共同的二百五十六維空間後，門控網路對每個片段、每個特徵維度產生權重。融合特徵再通過輕量 MIL head，輸出片段異常分數；訓練時用正常與異常影片袋的 Top-k 排序損失。

值得強調的是，兩個大型特徵抽取器都是凍結的，只訓練投影、門控與分類頭。這樣不只降低訓練成本，也使四個視覺骨幹的比較更乾淨：差異主要來自預訓練表徵與融合行為，而不是大量微調參數。

骨架分支：把人物姿態轉成可比較的動作表徵

建議時間：55 秒

逐字講稿

骨架分支分成四步。第一，YOLOX-m 先定位人物，再由 RTMPose-m 估計十七個 COCO 關節。第二，每個影格依關節平均信心保留前兩位人物，不足兩人時補零，並把座標正規化到負一到一。第三，使用 NTU RGB+D 120 預訓練、凍結的 CTR-GCN；它同時處理關節、骨骼、關節運動與骨骼運動四個串流。最後，每個六十四影格片段得到二百五十六維骨架表徵。

右下角也說明這個模態的邊界：骨架可降低衣著與背景影響，但人物太小、遮擋嚴重或姿態估計失敗時，訊號仍會變弱。這正是為什麼融合需要依輸入調整，而不是固定平均。

四種視覺語言骨幹：同一框架下比較規模與預訓練差異

建議時間：50 秒

逐字講稿

視覺分支比較四個骨幹：CLIP ViT-B/16、SigLIP2 Base、SO400M 與 Giant。它們涵蓋不同模型規模、預訓練目標與輸出維度。為了讓比較公平，我固定影片取樣、骨架分支、投影與融合結構、損失函數與訓練流程，只替換凍結的視覺骨幹。

這裡要檢驗的不是簡化成「模型越大就一定越好」，而是預訓練表徵與資料集事件型態之間是否有交互作用。後面結果會看到，UCF-Crime 最佳的是 Giant，但 XD-Violence 最佳反而是 SO400M，說明規模不是唯一因素。

晚期融合固定相加；門控融合逐片段選擇證據

建議時間：75 秒

逐字講稿

這張是方法最關鍵的比較。左邊晚期融合先讓兩個模態各自輸出分數，再固定各占二分之一。它簡單，但所有片段都被同樣對待；若骨架在某一段失敗，或視覺因背景產生高分，錯誤會直接進入最後分數。

右邊門控融合是在特徵層進行。兩路特徵先投影並做 LayerNorm，再產生二百五十六維門控向量 g ；也就是每個片段、每個維度都可調整。公式中 g 調節骨架項，一減 g 調節視覺項；另外保留兩路 residual，所以門控校準不佳時，也不會把任何模態完全刪除。

實驗上，門控相對晚期融合在 UCF-Crime 提升一點八到二點六個百分點，在 XD-Violence 提升十點九到十三點零。XD 的差距特別大，表示當模態品質或事件型態差異較複雜時，固定分數相加尤其容易失敗。

Top-k MIL：由最具證據的片段支持影片標籤

建議時間：30 秒

逐字講稿

訓練時，正常與異常影片都視為片段袋；兩邊挑出最高的 k 個片段，排序損失要求異常袋的 Top-k 平均分數至少比正常袋高一個 margin。總損失另加稀疏性與相鄰片段時間平滑。兩個特徵抽取器都凍結，實際只訓練約五十萬到一百零二萬個參數的輕量頭，每個設定少於五分鐘。

兩個資料集、兩種指標；評估協定需分開解讀

建議時間：40 秒

逐字講稿

實驗使用 UCF-Crime 與 XD-Violence。UCF 以影格層級 AUC 評估；本研究取得的是第三方重新散布的預抽影格版本，約六十四乘六十四、約三 FPS。因每部影片至少需要六十四影格，二百九十部測試影片中納入二百五十四部。

XD-Violence 來源與事件更異質、正負樣本不平衡，因此以 AP 評估。

解讀上，資料集內的消融與骨幹比較是公平的；UCF 絕對分數不宜與官方原始高解析影片協定直接等同比較。

同一套控制變因，依序回答 RQ1-RQ3

建議時間：20 秒

逐字講稿

(時間不足可略過本頁) 實驗矩陣依序回答三題：RQ1 比較單模態、晚期融合與門控融合；RQ2 在同一下游架構替換四種 VLM；RQ3 以四種污染、五個強度比較 Source、TENT、SAR 與本研究方法。主要結果皆報告三種子平均與標準差。

門控融合在兩個資料集皆達最佳整體結果

建議時間：80 秒

逐字講稿

先看主要結果。左圖比較視覺單模態、晚期融合與門控融合。UCF-Crime 的主要結果（預設設定的門控融合）是 Giant 骨幹，AUC 八十二點五、標準差零點四；XD-Violence 的主要結果（預設設定的門控融合）是 SO400M 骨幹，AP 七十八點七、標準差零點九。若被追問，GF 2-Person 名目更高，UCF 為 82.6 ± 0.3 、XD 為 79.2 ± 0.3 ，但在種子變異內，而且事後挑格構成輕度測試集選擇，因此論文不升格。

四個骨幹乘上兩個資料集共八組設定，門控都不低於視覺單模態，六組有正增益、兩組在報告精度下持平，平均提升零點六個百分點。晚期融合則明顯較弱，尤其在 XD-Violence；這說明多一個模態本身不保證提升，關鍵是如何管理模態可靠度。

骨架不是主角：整體增益小而一致，類別層級呈方向性支持

建議時間：65 秒

逐字講稿

骨架單獨使用時，UCF AUC 為六十八點八，XD AP 為四十點八，明顯低於視覺串流。因此我的結論不是骨架比視覺更強，而是骨架在部分片段或類別提供視覺缺少的結構性證據。整體證據是八組骨幹×資料集設定全部不劣於視覺單模態、平均加零點六個百分點的一致性；類別層級的分析方向上支持互補（人體動作類 +0.31、外觀類 -0.29、Shooting +1.05 最乾淨），但逐類樣本小、雜訊大，論文僅作為機制一致性檢查，不作為主張依據。

門控相對晚期融合在 UCF 提升約一點八到二點六，在 XD 提升十點九到十三點零；門控的價值是限制弱模態的傷害，同時保留有效片段的補充。

最佳骨幹依資料集而變：模型更大，不代表任務一定更好

建議時間：60 秒

逐字講稿

RQ2 的答案不是單純的規模排序。UCF-Crime 以 Giant 的八十二點五最佳；XD-Violence 則以 SO400M 的七十八點七最高。（Giant 為 76.8 ± 2.8 ，種子帶與 SO400M 平均重疊 - SO400M 屬觀察到的最高平均，非顯著勝出）這表示骨幹的預訓練資料、表徵空間與資料集事件型態之間存在匹配問題。

因此不應先假設最大骨幹一定最好，而應在目標資料上以一致的下游框架驗證。門控融合結論相對穩定，但觀察到的最佳平均仍受資料集影響。

事件時間可被定位，但分數校準仍有改善空間 (案例：Fighting047)

建議時間：55 秒

逐字講稿

左圖是一部 Fighting 影片的時間序列。紅色區域是真實異常，門控模型在事件開始後迅速升高，並在事件結束後回落，表示它確實能提供時間定位，而不是只做影片分類。

右圖則揭露一個重要限制：正常與異常影格雖然在排序上仍可區分，所以 AUC 不差，但許多正常影格的輸出分數也接近一，正常影格第七十五百分位約零點九八六。換句話說，這個分數適合做相對排序，不代表零點五這類固定閾值可以直接拿去警報。部署前仍需要獨立校準集、溫度縮放或事件層級的閾值設計。

[20 分鐘版可略] 可保留一句：「能定位事件，但絕對分數未校準」。

UCF-Crime-C：20 個污染條件下，來源模型出現系統性退化

建議時間：60 秒

逐字講稿

接下來回答 RQ3。我在 UCF 測試集的污染版本 UCF-Crime-C 建立四種影像污染：Gaussian noise、motion blur、JPEG 壓縮與 brightness，每種各有五個強度，共二十個條件。熱圖顯示，不更新模型的來源模型在多數條件都有退化，而且不同骨幹的弱點不完全一致；其中高強度 Gaussian noise 是最能使視覺語言串流崩潰的條件。

這件事有兩個含意。第一，乾淨資料上的最佳模型不一定在所有污染下都最佳；第二，若要在測試時調整模態權重，不能只看一般特徵位移，而要確認視覺串流是否真的失去區分片段的能力。這正是後續可靠度重加權的設計依據。

本協定下，TENT / SAR 幾乎不改變 AUC

建議時間：70 秒

逐字講稿

我先測試兩個代表性方法 TENT 與 SAR。表中的變化都小於零點一個 AUC 百分點，有些甚至微幅下降，整體可視為沒有實質效果。這不是因為程式完全沒跑，而是方法的主要適應槓桿與模型架構不匹配。

TENT 與 SAR 經常透過熵最小化更新正規化相關參數，尤其在含 BatchNorm 的模型上，批次統計可以隨測試分布改變。但 CLIP 與 SigLIP2 視覺 Transformer 主要使用 LayerNorm，沒有可用同樣方式更新的批次統計。此結果為三種子、連續 (continual) 協定、單一參考學習率 10^{-3} (未做學習率掃描) 下所得；結論主要依據排序不變機制，是我們論證的結構性限制。

因此，負結果的貢獻是界定方法邊界：不能把在 BatchNorm 網路有效的 TTA，直接假設會轉移到凍結融合頭的 LayerNorm 適應面。

可靠度重加權：不更新模型，改為重分配模態信任

建議時間：85 秒

逐字講稿

既然直接更新 LayerNorm 參數沒有幫助，我改變問題：不去改模型，而是判斷何時應該降低視覺串流的影響。第一步把骨架輸入設為零，讓同一個融合頭輸出 visual-only 的片段分數。第二步比較污染條件與乾淨參考的分數標準差；如果視覺分數被壓縮、失去區分片段的能力， w_{vl} 就會低於一。第三步再檢查骨架特徵相對乾淨參考的位移，形成安全閘 s ；若骨架也受污染，就禁止改道。最後， w 等於一，減去「(一減 w_{vl}) 乘上 s 」；也就是只有骨架可信 (s 接近一) 時， w 才會往 w_{vl} 下調。

因此只有「視覺判別力崩潰、但骨架串流仍完好 (乾淨快取)」兩個條件同時成立，模型才會向骨架改道；任何一項不成立， w 就等於一，輸出與來源模型完全相同。這個方法不需要梯度、最佳化器或標籤，但統計量是以整個污染條件彙整，所以屬於 transductive 協定，而不是單樣本線上適應。

要說明的是：本基準中 Gaussian 與 brightness 條件重用乾淨骨架快取，blur 與 JPEG 則從污染影格重抽取 (論文 4.3 節揭露)。因此 Gaussian 的增益量化的是「仍存在完好骨架串流時」改道的上限，而非同一鏡頭全鏈路的穩健性；JPEG 列 (骨架重抽取後安全閘為零、增益為 0) - 這是誠實對照。

整體平均提升 +1.21；改善幅度隨骨幹與污染而異

建議時間：65 秒

逐字講稿

結果上，可靠度重加權在四個骨幹平均都有正增益。CLIP 提升零點六七、Base 一點五零、SO400M 二點二四、Giant 零點四二；把四個骨幹與二十個污染條件平均後，來源模型由六十點六提升到六十一點八，平均增加一點二一。最高增益是 SO400M 在第五級 Gaussian noise 的十三點二。

右邊熱圖顯示，增益主要集中在 Gaussian noise，而且會隨強度增加；對 motion blur、JPEG 與 brightness，骨架安全閘或視覺可靠度判斷會讓 w 保持一，因此結果與來源模型相同。這也是我把它定位為「選擇性救援」的原因：它不是讓模型對所有污染免疫，而是在視覺判別力真的崩潰、骨架串流仍完好（乾淨快取）時才介入。

限制需要誠實界定，但不等於主要結論失效

建議時間：75 秒

逐字講稿

這一頁我主動界定四個研究邊界。第一，UCF 使用第三方重新散布的預抽影格版本，因此最適合支持同一協定內的消融與骨幹比較，跨論文絕對值要保守。第二，原先設定的最低目標是 UCF 八十三、XD 八十，但實測是八十二點五與七十八點七；我保留真實結果，不用目標值包裝。第三，二十個污染條件也參與了策略選擇，可靠度統計又是整個條件彙整，因此仍有 transductive 成分，未來應把開發污染與最終測試污染分開，並研究串流估計。

第四，早期時間平滑損失曾誤沿 batch 軸計算。我修正後做了完整二十九組設定重跑；主要八十二點五的結果重現，三種子平均僅差負零點零六、皆在種子標準差內；非頭條格另有較大位移（29 格整體平均約負零點一六，Skeleton-Only 列平均約負一點四），但方法排序與所有質性結論不變。

這些限制不是把研究作廢，而是精確說明證據能支持到哪裡。最核心的比較仍成立：在一致協定下，門控跨八個設定都不劣於視覺單模態；TENT / SAR 的 LayerNorm 限制與重加權的平均增益也可重現。

三個研究問題的答案

建議時間：80 秒

逐字講稿

最後回到三個研究問題。RQ1：雙模態有價值，但關鍵是門控融合，而不是把兩個分數固定相加；在四個骨幹與兩個資料集共八組設定中，門控都不低於視覺單模態，並明顯優於晚期融合。RQ2：門控結論跨骨幹成立，但最佳骨幹依資料集改變；UCF 最佳為 Giant 的八十二點五，XD 最佳為 SO400M 的七十八點七。RQ3：TENT 與 SAR 無法直接轉移到凍結融合頭的 LayerNorm 適應面；不更新模型、只在視覺崩潰且骨架可信時改道的可靠度重加權更符合此架構，二十個污染條件平均提升一點二一。

因此，本研究最核心的結論是：多模態的價值不只是加入更多資訊，而是依情境管理不同證據的可靠度。我的報告到這裡，謝謝各位委員聆聽，敬請指教。

[20 分鐘版] 這張仍建議完整保留，因為它直接回答三個研究問題；若超時，可將每題壓縮成一個句子。

備用投影片

逐字講稿

本頁為正式報告結束後的備用投影片分隔頁，不計入建議時間。

一致性重跑：修正平滑實作後，主要排序不變

逐字講稿

若委員詢問舊平滑實作影響：先說明 29 格全部重跑，再把頭條結果的負零點零六與 29 格整體平均負零點一六分開。最大單格負四點一三發生在 Skeleton-Only s42，但該列本來就有正負二點八的種子帶；門控相對視覺與方法排序都沒有改變。

可學習純量晚期融合：學到的仍接近等權

逐字講稿

若委員問為何不只學一個 α ：八個設定乘三個種子中， α 收斂在零點四四到零點四九，與等權初始化幾乎相同；和固定等權差不超過零點九，但仍落後門控。重點是靜態權重無法依每個輸入改變模態信任。

254 / 290 : 為何排除 36 部 UCF 測試影片 ?

逐字講稿

排除不是依結果挑樣本，而是架構最小輸入長度造成的預先規則。三十六部影片短於六十四影格，占十二點四趴；論文已揭露，並可由 `data/ucf_total_frames.json` 重現。

門控行為證據：gate 值依類別系統性變化

逐字講稿

這兩張圖顯示 gate 值會隨類別系統性變化，支持門控確實在管理模態信任。但這是 CLIP、單一種子 s42 的探索性分析，只能作為機制一致性檢查，不應升格成逐類效能主張。

分數校準與部署：排序可用，不等於固定閾值可直接上線

逐字講稿

頭條 UCF 設定中，正常影格第七十五百分位是零點九八六；異常與正常平均分數為零點八七四與零點三八二。AUC 與 AP 只看排序，因此部署時不能直接沿用固定閾值。可用保留正常影格做事後校準，或改用滑動視窗內的相對排序警報，兩者都不需要重訓骨幹。

TTA 方法選擇流程：原則先定，再做跨條件重現

逐字講稿

六策略搜尋的實際六條線是：位移門控混合、通道選擇、投影空間校正、融合閘調變、骨架分數混合、以及開放式探索；勝出者為可靠度重加權（論文 6.3 節有逐一命名）。前置研究階段先檢驗熵最小化與特徵統計方法，其中 CORAL 於留一污染條件驗證中淘汰。最終方法則在篩選時未使用的骨幹、強度與種子上重現。不過二十個污染條件仍參與策略形成，因此殘餘選擇風險已在論文第六章揭露。