

你的論文到底在幹嘛：從頭到尾一次講懂

弱監督暴力影片異常偵測：骨架 + 視覺語言雙模態融合，與測試時期自適應研究

0. 一分鐘電梯版（先把這段背起來）

整本論文一句話

「我用兩個凍結的預訓練模型——一個看畫面語意（CLIP/SigLIP2）、一個看人體骨架動作（CTR-GCN）——只訓練一個很小的閘控融合頭，在只有影片級標籤的情況下偵測監視器影片裡的暴力事件；然後我進一步研究：當部署現場畫面劣化時，主流的測試時期自適應方法（TENT/SAR）在這種架構上結構性無效，而我提出的『判別可靠度重加權』——讓融合改去信任沒壞掉的那個模態——有效。」

三個研究問題（RQ）與三個答案：

- **RQ1 融合有用嗎？** → 有，但增益「小而一致」：8 組設定全部不輸純視覺，其中 6 組嚴格更好，平均 +0.6 點。而且必須用學習式 gating——傻傻各半平均（late fusion）反而會更差。
- **RQ2 換視覺骨幹有差嗎？** → 有，而且兩個資料集偏好不同：UCF-Crime 越大越好（Giant），XD-Violence 在融合後由 SO400M 勝出。
- **RQ3 TTA 能救劣化畫面嗎？** → TENT/SAR 不能（每個骨幹變化都 <0.1 點，是結構性零結果）；我的免標籤重加權可以（4 個骨幹全正，平均 +1.21 點，最高單一條件 +13.2 點）。

頭條數字（必背）

UCF-Crime：82.5 ± 0.4 % 幀級 AUC（Gated Fusion + SigLIP2 Giant）

XD-Violence：78.7 ± 0.9 % AP（Gated Fusion + SigLIP2 SO400M）

全部都是三個種子（42, 123, 2024）的平均。

1. 為什麼做這個題目（背景故事）

把整個動機想成四層堆疊，每一層解決上一層的問題：

第一層：監視器太多，人看不完。車站、校園、街頭到處是攝影機，一個保全同時只能盯幾個畫面，而且盯久了注意力會掉。所以需要自動分析。

第二層：暴力事件最需要抓，但最難用一般分類器做。打架、搶劫、槍擊——晚一分鐘反應代價最高，但這些事件又**很稀有、樣態很雜**，蒐集不到「每一類大量標好的樣本」。所以改用「異常偵測」的思路：不去認出固定類別，而是給每一幀打一個「異常分數」——它跟正常活動差多遠。

第三層：逐幀標註太貴 → 弱監督。要標出每部影片裡異常事件的精確起訖時間，成本高到不可行。所以採用「弱監督」設定：訓練時**只知道整部影片有沒有異常**（影片級標籤），但測試時要輸出**每一幀**的分數。這就是 Sultani et al. 2018 建立的 MIL（多實例學習）典範。

第四層：現有方法有四個缺口，就是我的切入點。

四個研究缺口（Gap）

1. **幾乎全是單一視覺模態**——骨架異常偵測自成一派（多為無監督），沒人把「骨架動態 + 視覺語言特徵」放進同一個弱監督框架。
2. **CLIP 這類模型看不太懂「動作」**——它們是用靜態圖文對訓練的，擅長場景語意，但暴力恰恰是「動作」現象。
3. **沒人研究骨幹敏感度**——每篇論文都只用一個骨幹就下結論，好像結論跟骨幹無關似的。
4. **TTA 方法假設 BatchNorm，但現代架構用 LayerNorm**——TENT/SAR 靠重估 BatchNorm 的統計量運作；LayerNorm 沒有這種統計量，能不能轉移過來根本沒人驗證過。

2. 系統怎麼運作：兩位偵探的比喻

比喻

想像你派**兩位偵探**看同一段監視器畫面：

 **偵探 A（視覺語言流）**：看「這是什麼場景、有什麼東西」——他學識淵博（CLIP/SigLIP2 在幾億張圖文對上訓練過），但對「人的肢體怎麼動」不太敏感。

 **偵探 B（骨架流）**：只看「人的關節怎麼動」——揮拳、倒地、扭打。他不受衣著、光線、背景干擾，但單獨作業能力弱很多。

兩位偵探都是「凍結」的——我不重新訓練他們。我只訓練一個小小的「主管」（**閘控融合頭**），主管的工作是：針對每一段畫面，決定「這次該多信 A 還是多信 B」，然後給出異常分數。

2.1 資料怎麼流過整個管線

影片 → 切成不重疊的 **64 幀片段 (snippet)** (兩條流共用同樣的切法，天生對齊)

└ 骨架流：YOLOX 偵測人 → RTMPose-m 抽 17 個關節點 (每幀保留信心最高的 2 人) → 凍結的 CTR-GCN 編碼 → 每段一個 **256 維** 向量

└ 視覺流：每秒約取 1 幀 → 凍結的 CLIP/SigLIP2 嵌入 → mean 池化 + max 池化串接 → 每段一個 **2d 維** 向量 (CLIP 1024 維 ~ Giant 3072 維)

└ 融合頭 (唯一有訓練的部分)：兩邊各投影到 **256 維** + LayerNorm → 算出**逐維度的 gate** → 混合 + 殘差 → 再一個 LayerNorm → MIL 頭輸出**每段一個異常分數**

細節備忘：骨架張量形狀是 (幀數, 2人, 17關節, 3)——第三維是 x, y 加上關節信心值 (保留信心值讓後端可以自動降低「不確定關節」的權重)。CTR-GCN 用 NTU RGB+D 120 預訓練權重，跑四個 stream (關節、骨向量、關節速度、骨速度)，以 1.0/1.0/0.5/0.5 加權平均。

2.2 為什麼堅持「凍結」骨幹？(口委必問)

1. **硬體現實**：只有一張 RTX 4090 (24GB)，端到端微調視覺語言大模型跑不動。
2. **實驗乾淨**：骨幹永遠不變，所以任何效能差異都可以歸因於「表徵本身 + 小融合頭」，不會被不同的微調軌跡污染。
3. **讓大規模比較變便宜**：特徵抽一次就快取起來，之後每個訓練配置不到 5 分鐘就跑完——這是整個 6 變體 × 4 骨幹 × 3 種子網格能做完的原因。可訓練參數只有 0.50M ~ 1.02M。

2.3 Gated Fusion 白話拆解 (核心公式)

比較對象是最笨的 **Late Fusion**：兩個模態各自打分，然後**固定各半**相加： $a = \frac{1}{2}h_s(s) + \frac{1}{2}h_v(v)$ 。這隱含一個很強的假設——「兩位偵探每次都一樣可靠」。第 5 章證明這個假設會出事。

Gated Fusion 分四步：

1. **投影對齊**：骨架 256 維、視覺最多 3072 維，尺寸差太多，各自先線性投影到共同的 256 維空間，再各過一個 LayerNorm (LN_s 、 LN_v) 把尺度拉平——不讓誰靠「數值比較大」就贏。
2. **算 gate**：把兩個投影後的向量串接，過一層線性 + sigmoid，得到 $g \in [0,1]^{256}$ 。注意是**逐維度**的 gate，不是一個純量——因為不同維度編碼不同資訊 (動作、物件、場景)，信任度應該可以每維不同。而且 gate 同時看到兩個模態，所以它能對「兩條流的關係」反應——例如偵測不到可靠骨架時就調低骨架維度。
3. **混合 + 殘差**： $f = LN_f(g \odot \hat{s} + (1-g) \odot \hat{v} + \hat{s} + \hat{v})$ 。後面那個「 $+\hat{s} + \hat{v}$ 」是殘差，展開後等效權重是 $(1+g)\hat{s} + (2-g)\hat{v}$ ——意思是 **gate** 只能調整相對比重，永遠不能把任何一個模態完全關掉。這是安全設計：就算 gate 學壞了，最糟也只是退化成不等權的加法融合，不會退化成單模態。

4. 為什麼用 LayerNorm 不用 BatchNorm：MIL 的 batch 混著正常包和異常包，兩者分數統計本來就系統性不同，batch 級統計會不穩又被語意污染；LayerNorm 每個樣本各自正規化就沒這問題。這個選擇是第 6 章整個 TTA 故事的伏筆——LayerNorm 沒有可重估的 running statistics。

3. 怎麼在只有影片級標籤下訓練：MIL 白話

比喻

你知道「這袋水果裡至少有一顆壞的」（異常影片），另一袋「全部都是好的」（正常影片），但不知道具體哪顆壞。策略：讓模型幫每顆水果打分，然後要求「壞袋裡分數最高的幾顆」要比「好袋裡分數最高的幾顆」高出一個安全邊際（margin=1）。模型為了達成這個排序要求，只能自己學會找出真正壞的那幾顆——這就是免逐幀標註還能逐幀定位的原理。

實作細節：每個 batch 是「正常包 + 異常包」成對；每包固定取 $T=32$ 個片段；取每包 top-k（ $k=3$ ）的平均分數來比（比只取最大值更抗雜訊）。總損失 = ranking loss + 稀疏項（ $\lambda_1=8\times 10^{-3}$ ，鼓勵大部分片段低分，因為異常只佔影片一小段）+ 時間平滑項（ λ_2 ，懲罰相鄰片段分數劇烈跳動）。

一個必記的資料集差異

時間平滑權重是**唯一**隨資料集不同的超參數：UCF-Crime 用 $\lambda_2=8\times 10^{-4}$ ，XD-Violence 用 $\lambda_2=0$ 。原因：XD 是電影/新聞/體育剪輯，鏡頭切換快，強迫分數平滑反而過度正則化、讓 AP 不穩定；關掉之後 AP 變好、種子變異也大幅收斂。UCF 是連續固定機位畫面，平滑有小幫助。

其他訓練設定（可能被抽問）：AdamW、 $lr=1\times 10^{-4}$ 、warmup 5 epochs 後 cosine 退火、batch 16 對（32 部影片）、最多 50 epochs、early stopping patience 10（用**驗證集 MIL loss** 選模型——因為驗證集也只有影片級標籤，幀級資訊從不參與任何訓練或選模決策，測試標註只在 evaluate.py 裡載入，防洩漏）。驗證集是訓練集切 15%、分層、固定一次、全部實驗共用。

4. 實驗設定：兩個資料集、兩個指標

	UCF-Crime	XD-Violence
規模	1,900 部未剪輯監視器影片	4,754 部，來源混雜（電影/新聞/體育/網路）
類別	13 類異常 + 正常（Abuse, Arrest, Arson, Assault, Burglary, Explosion, Fighting, RoadAccidents, Robbery, Shooting, Shoplifting, Stealing, Vandalism）	6 類（Fighting, Shooting, Riot, Abuse, Car Accident, Explosion）
切分	訓練 800 正常 + 810 異常；測試 290（150 正常 + 140 異常）	訓練 3,954；測試 800
指標	幀級 AUC（排序型，不受類別不平衡影響）	幀級 AP（更重視排最前面的幀，對小變動更敏感）
畫質重點	64×64 像素、約 3 FPS 的重發布幀版（比別人用的原始影片低畫質！）	原生影片解碼，約 24 FPS
64 幀片段等於	約 20 秒	約 2.7 秒

必須主動揭露的兩件事

① **64 幀排除**：骨架流以 64 幀為最小單位，短於 64 幀的影片被排除——UCF 172 部（測試集剩 254/290 部可評），XD 只有 1 部。被排除的都是最短的片段（不到約 21 秒）。論文各處都有揭露。

② **分數展開協定不對稱**：模型打的是片段分數，評估是逐幀。UCF 用「完整幀網格」（尾端不足的幀重複最後一段的分數；靠 committed 的幀數 manifest 讓數字可從 repo 重現）；XD 用「截斷到整數個 64 幀窗」的網格。同資料集內比較不受影響，但兩種網格的絕對數字不能互換——第 6 章的劣化 AUC 用的是截斷網格，所以不能直接跟 82.5 比。

5. 主結果一：融合到底有沒有用 (RQ1)

5.1 主消融表 (記趨勢，別背整張表)

UCF-Crime AUC (%)	CLIP B/16	SigLIP2 Base	SO400M	Giant
Skeleton Only	68.8±2.8	—	—	—
Visual Only	81.2±0.1	78.5±0.5	81.1±0.3	82.4±0.2
Late Fusion (各半平均)	78.9±0.4	77.2±2.0	79.1±1.3	79.9±0.8
Gated Fusion	81.4±0.3	79.0±0.1	81.3±0.3	82.5±0.4

XD-Violence AP (%)	CLIP B/16	SigLIP2 Base	SO400M	Giant
Skeleton Only	40.8±0.6	—	—	—
Visual Only	74.6±1.5	74.5±2.1	76.6±2.2	76.8±1.0
Late Fusion	63.9±0.5	63.6±0.7	65.7±0.5	65.7±0.4
Gated Fusion	76.5±0.9	74.5±0.9	78.7±0.9	76.8±2.8

5.2 三個要講的發現

發現一：骨架有互補價值，但要誠實地說「小而一致」。骨架單獨只有 68.8 AUC / 40.8 AP，遠弱於視覺。但 gated fusion 在 8 組 (4 骨幹 × 2 資料集) 全部不輸純視覺、6 組嚴格更好 (2 組在顯示精度下打平)、平均 +0.6 點。把 8 組當成 8 次配對觀察做符號檢定得 $p \approx 0.03$ (要附帶說：8 組共用同一條骨架流所以彼此相關，這是「一致性檢查」不是 8 次獨立驗證)。最大增益在 XD：CLIP +1.9、SO400M +2.1 AP——合理，因為 XD 的打架類事件本質上就是身體動作。

發現二：Late fusion 會反過來害你。UCF 上 CLIP late fusion 78.9，比純視覺 81.2 低 2.3 點——加了第二個模態反而更差。XD 更慘：late fusion 掉到 63~65，比 gated 低 10~13 點。原因：固定各半意味著弱骨架訊號永遠拖累一半分數，沒有任何機制降低它的權重。兩個模態越不對等 (XD 的差距 40.8 vs 74.6 最懸殊)，等權平均傷害越大。**教訓：怎麼融合，跟要不要融合一樣重要。**

發現三：連「學一個純量權重」都救不了 late fusion。控制實驗：把固定 $\frac{1}{2}$ 換成一個可學的混合係數——結果它收斂在 0.44~0.49 (幾乎沒離開等權初始值)，分數跟固定版差不到 ± 0.9 點，還是遠輸 gated fusion。結論：**靜態權重 (無論固定或學到的) 都不行，重加權必須是輸入相依的。**這個實驗直接堵住「你的 gate 會不會只是學到一個常數」的質疑——附圖也顯示 gate 值隨類別系統性變化，不是常數。

5.3 統計穩健性 (如果被問「你的數字可信嗎」)

- **Bootstrap 信賴區間** (影片級重抽樣， $B=2000$) : UCF 95% CI 是 [75.6, 88.0]，寬達 12.4 點！這不是我的方法爛，是**基準本身的性質**——UCF 測試集只有約 250 部影片 (不到 130 部異常)，任何在這個測試集上報單一 AUC 的方法都繼承這個不確定度。所以文獻上一兩點的差距都該保守解讀 (包括對我有利的方向)。XD 測試集 800 部，CI 寬 6.1 點，結論比較穩——這也是為什麼論文強調「競爭力在 XD 上最清楚」。
- **種子敏感度** : UCF 很穩 (std 0.1–0.4) ; XD 上只有 Giant 特別飄 (std 2.8)。所以 XD 上絕不拿三種子數字跟單種子數字比。

5.4 失敗分析 (展現你了解模型的弱點)

- **兩種失敗型態** : ①「整片飽和」——模型判定整部影片都像異常，每幀都逼近 1.0，片內排序全靠雜訊 (Burglary017 AUC 只有 0.06) ; ②「短事件漏抓」——事件只佔影片 1.9% (RoadAccidents011)，64 幀池化直接把它稀釋掉。
- **校準很差 (重要弱點，主動講比被抓到好)** : 分數分布極度雙峰 (不是 0 就是 1)，四分之一的正常幀分數超過 0.98。AUC 是排序型指標所以吸收得了，但任何固定閾值的實際部署都會狂誤報。結論：**排序 OK、校準不行**，這是目前這顆頭的根本限制，解法 (溫度縮放、等滲回歸、滑動窗排序警報) 列為未來工作、不需重訓骨幹。
- **類別層級** : UCF 最強 Stealing 99.3 / Vandalism 97.5 / Assault 97.2 ; 最弱 RoadAccidents 87.1 / Robbery 88.6 / Explosion 88.8 (短促、視覺瞬變的事件被 64 幀池化傷最重)。XD 分布更寬 : Riot 94.0、Fighting 81.1 很強 ; Abuse 43.6、Car Accident 48.2 掉到 50 以下 (Abuse 是近身、細微、沒有明顯全身動作的暴力)。

6. 主結果二：骨幹網路研究 (RQ2)

同一條管線、只換視覺骨幹，4 個候選跨兩個軸：訓練目標 (CLIP 的 softmax 對比損失 vs SigLIP2 的 sigmoid 損失) 和容量 (512 → 768 → 1152 → 1536 維嵌入)。

- **UCF** : 容量越大越好。Giant > SO400M $\approx$ CLIP > SigLIP2 Base。有趣的反例：SigLIP2 Base 跟 CLIP 同是 ViT-B/16 架構，卻輸 CLIP 2.7 點——訓練配方的優勢不會自動轉移到監視器畫面。
- **XD** : 純視覺看不出差別 (全在種子變異內)，融合之後 SO400M 才浮出來 (78.7)。這是關鍵論點：偏好是「透過融合浮現」的，代表骨幹的特徵幾何跟骨架流經過 gate 的互動才是決定因素，光看視覺單獨的排名預測不了。
- **骨架的幫助量本身依賴骨幹** : CLIP 和 SO400M 融合增益最大 (+1.9 / +2.1 AP)，Base 和 Giant 幾乎打平。方法論意義：如果我只評 CLIP (像多數論文那樣)，互補性會被高估；如果只評 Giant，融合會看起來像零結果。**這就是為什麼多骨幹評估是必要的。**

7. 主結果三：TTA 三幕劇 (RQ3) ——論文最有故事性的部分

情境設定：部署現場的畫面會劣化（低光噪點、手震模糊、頻寬壓縮、光照變化）。我建了 **UCF-Crime-C**：4 種劣化 × 5 個嚴重度 = 20 個條件（照 ImageNet-C 協定）。

劣化類型	模擬什麼	骨架要不要重抽？
高斯噪點	低光感光元件噪訊	不用（RTMPose 對它免疫，重用乾淨快取）
亮度偏移	光照變化	不用（同上）
動態模糊	手震 / 快速移動	要（模糊會抹掉肢體邊界）
JPEG 壓縮	頻寬受限傳輸	要（區塊瑕疵改變偵測到的姿態）

這個「骨架有時乾淨、有時也壞」的不對稱，就是最後我的方法能運作的結構基礎。**先確立損害規模**：不做任何調適時，20 條件平均 AUC 掉到 63.7 / 57.0 / 58.9 / 62.8（CLIP/Base/SO400M/Giant）——比乾淨的 82.5 低了約 20 點。劣化是真實且巨大的問題。

第一幕：TENT/SAR 熵最小化 → 結構性零結果

方法背景：TENT 在測試時最小化模型預測的熵（讓模型「更有自信」），只更新正規化層參數；SAR 加上樣本過濾和平坦極小值搜尋。它們原生設計給 **BatchNorm** 網路——那裡調適有兩個管道：重估 running statistics + 梯度更新仿射參數。

移植到我的架構後只剩一個管道：LayerNorm 沒有 running statistics，所以只能微調融合頭 3 個 LayerNorm 的仿射參數——**全模型只有 1,536 個純量可動**，其他全凍結。目標函數換成二元熵（因為輸出是 sigmoid 分數不是 softmax 分布）。

結果：三種子、連續協定下，TENT 和 SAR 在每個骨幹上的變化都 <0.1 點（最大 $|\Delta|=0.082$ ）。等於零。

為什麼說是「結構性」而不是「沒調好」：AUC 是排序指標，對分數的任何單調變換免疫——要改善它必須**重新排序**片段。劣化造成的偏移住在上游的凍結骨幹特徵裡，1,536 個仿射純量在凍結特徵之後做的小幅修正，根本沒有能力重排池化後的分數排序。（誠實揭露：只跑了參考學習率 $1e-3$ 、沒掃 lr，所以「絕對不行」的斷言是靠這個排序不變性機制支撐的。）

路上踩過的兩個坑（口委若問「你確定不是 bug？」就講這段，反而加分）

坑一：dropout 沒關。最早的探索性實驗顯示 TENT/SAR「有小改善」——查程式碼發現調適模式誤把 dropout 留在啟用狀態，隨機性製造了每條件約 1.07 點的假雜訊。關掉、全部設種子後，改善消失、結果 bit-級可重現。教訓：排序指標特別會把「評估隨機性」偽裝成「調適增益」。

坑二：episodic 協定結構性失效。逐影片調適-重設的協定下，98.4% 的 UCF 測試影片 ≤ 32 片段、單批打完分——參數更新永遠影響不到那部影片自己的分數，然後就被重設丟掉。難怪到處都是 +0.000。所以改用 TENT/SAR 原生的 continual-online 協定（每個劣化串流重設一次、跨影片累積），並用探針驗證調適確實會改變輸出後才報數。

第二幕：NORM/CORAL 特徵統計還原 → 排序破壞

換個思路：不調參數，直接把劣化特徵的統計量（均值/變異數，或整個共變異數）「搬回」乾淨訓練特徵的統計量。這確實作用在偏移真正所在的特徵空間。探索階段 CORAL 看起來有 +0.9 點——但驗證拆穿它：白化會重排 SigLIP2 骨幹的判別方向、效果正負號隨骨幹翻轉，用「留一條條件交叉驗證」（部署時真正做得到的免標籤選點方式）評分是 **-1.62 點、四個骨幹零個為正**。診斷：失敗模式不是「統計量弄錯」，而是**排序破壞**——任何移動特徵但不保證保持分數排序的變換，傷害排序指標跟幫助它一樣容易。

第三幕：我的方法——判別可靠度重加權（disc_reweight）

一句話

「不調參數、不搬特徵——**改變凍結融合『信任哪個模態』**。當視覺流的判別訊號崩潰、而骨架流還健康時，把融合路由到骨架那邊。零參數更新、零標籤、零可調超參數。」

三個純量，全部可從無標籤資料算出：

1. **視覺可靠度** $w_{vl} = \min(1, \sigma(\text{劣化下視覺獨奏分數}) / \sigma(\text{乾淨時視覺獨奏分數}))$ 。「視覺獨奏分數」= 把骨架輸入清零後跑融合頭得到的分數。直覺：看它「還分不分得開」片段（分數的離散度），而不是看特徵統計有沒有偏移——因為排序指標在乎的就是分離度。分數全部擠在一起 $\rightarrow \sigma$ 崩掉 $\rightarrow w_{vl} \rightarrow 0$ 。
2. **骨架可靠度閘** s ：只有骨架自己乾淨時才可以路由過去。比較骨架特徵在該劣化條件下的平均逐通道偏移 z_{skel} 與自然的乾淨訓練 $\rightarrow$ 乾淨測試偏移 z_0 ：偏移 $\approx$ 自然水準 $\rightarrow s \approx 1$ （放行）；偏移 ≥ 2 倍 $\rightarrow s = 0$ （關閉路由）。2 倍是先驗定的錨點、不是調出來的，而且實際上 s 都飽和在 $\{0,1\}$ ，確切值不影響結果。

3. 路由純量 $w = 1 - (1 - w_{vl}) \cdot s$ ，乘在視覺投影特徵上（必須在 LN_v 之後乘——在之前乘會被 LayerNorm 的重新正規化抵銷掉）。兩個條件都成立才會降權：視覺真的崩了、且骨架可信。任一不成立 $\rightarrow w=1 \rightarrow$ **模型跟原始模型 bit-級一致**。失敗模式是「什麼都不做」，所以可以永遠開著。

結果數字

骨幹	Source-Only	Ours	Δ (三種子 mean $\pm$ std)
CLIP ViT-B/16	63.7	64.4	+0.67 $\pm$ 0.23
SigLIP2 Base	57.0	58.5	+1.50 $\pm$ 1.14
SigLIP2 SO400M	58.9	61.1	+2.24 $\pm$ 0.24
SigLIP2 Giant	62.8	63.3	+0.42 $\pm$ 0.12
平均	60.6	61.8	+1.21

所有 12 個「骨幹 $\times$ 種子」格子全部為正（最小 +0.27）。增益幾乎全部集中在高斯噪點（該家族跨骨幹平均 +4.83；SO400M 的家族平均 +8.95；單一最大格是 SO400M 嚴重度 5 的 +13.2）。

三個容易搞混的聚合層級（口委抓數字時的保命符）

+1.21 = 4 骨幹 $\times$ 20 條件的總平均 | +4.83 = 高斯家族的跨骨幹平均 | +8.95 = SO400M 一個骨幹的高斯家族平均 | +13.2 = SO400M 在高斯嚴重度 5 這一格。四個數字不可互換。

為什麼增益集中在高斯噪點？因為它剛好是「一個模態死、另一個活」的條件：噪點最摧毀視覺流的判別力，但骨架用的是乾淨快取（RTMPose 對噪點免疫）。模糊/JPEG 的零不是方法失敗，是閘門在工作：那兩族的骨架也是從劣化幀重抽的（自己也壞了）， s 閘關閉路由、停留在原模型——不會把融合路由到一個同樣壞掉的模態上，寧可不動也不受傷。亮度族則是視覺根本沒壞（ $w_{vl} \approx 1$ ），無事可做。

四個誠實 caveat（自己先講）

1. 這是「救援」不是「本質強健」：機制是路由到骨架，收益上限是骨架融合的天花板，融合特徵本身沒有變得更抗劣化。
2. 離散度代理可能誤判：SigLIP2 Base 有一個種子在 high 嚴重度 5 掉了 3.2 點——它的分數是「壓縮但沒失序」，代理把壓縮誤認為崩潰而過度路由。這是免標籤估計的誠實代價（該骨幹三種子平均仍是 +1.50 為正）。
3. Transductive（轉導式）：可靠度統計是把整個劣化條件的測試資料先池化起來算的——假設能整批拿到，不是線上串流部署。這是該領域標準評估協定，但誠實說它不是部署配方；串流版列

為未來工作。

4. 策略搜尋在同樣 20 個條件上評分：六策略搜尋跟最終比較用同一組條件，殘餘選擇風險存在。
緩解：所有候選都免標籤免調參、LOCO 檢查淘汰了 CORAL、採納方法的增益在篩選時沒看過的骨幹/嚴重度/種子上重現。

LayerNorm barrier 總結論（跨領域的貢獻點）：對凍結、LayerNorm、排序評估的偵測器——參數調適（TENT/SAR）構不到偏移、特徵還原（NORM/CORAL）會破壞排序；行得通的是**可靠度感知的模態路由**。而且這條路只有雙模態架構才有——單流偵測器面對同樣的 barrier 時，根本沒有健康模態可以路由過去。

8. 跟世界比：SOTA 定位（口委最愛的戰場）

核心立場（背熟）

「我不主張 state-of-the-art。領先方法約 88–91% UCF AUC，但它們用了我刻意排除的元件：可學文字分支（VadCLIP 88.0、DSANet 89.4）、訓練期輔助模態（PI-VAD 90.3）、微調的多模態 LLM（Holmes 系列）。我的貢獻軸是正交的：可重現的單 GPU 雙模態管線 + 完整的免標籤穩健性研究——這些高分方法沒有一篇做劣化穩健性/TTA 研究。5–9 點的差距應讀作『被排除元件的成本』，不是融合方法本身的缺陷。」

公平比較區（regime-matched subset）：凍結特徵、無文字分支、無微調、單 GPU 級頭部——

方法	年份	UCF AUC	XD AP
CLIP-TSA（最接近的比較對象）	2023	87.58	82.19
UR-DMU	2023	86.97	81.66
MGFN-I3D	2023	86.98	79.19
RTFM	2021	84.30	77.81
本論文	2026	82.5	78.7
Sultani et al.（開山之作）	2018	75.41	—

- **XD 上：**78.7 跟 RTFM（77.8）、MGFN（79.2）同一水位——同區間內具競爭力，這是講競爭力時最有底氣的地方。
- **UCF 上：**82.5 落後同區所有現代方法。最接近的 CLIP-TSA（87.58）同樣用凍結 CLIP 視覺特徵、無文字——差距**假設**來自它的時間自注意力模組和多裁切聚合（我的極簡頭刻意不做時間建模），但**沒有實驗隔離證明**，這點要老實承認。
- **反向亮點：**兩個「training-free」LLM 方法 LAVAD（80.3/62.0，雙 3090）和 EventVAD（82.0/64.0，80GB A800）——我的單張 4090 小頭在 UCF 打平或超越、XD 大勝（78.7 vs 62/64）。論點：「training-free 不等於便宜」，凍結特徵 + 小可訓練頭仍是單 GPU 研究者最強的部署取舍。
- **可重現性優勢：**我全部是三種子平均、固定切分、單一協定、headline 可從 committed manifest 重現；對比某些最高分是單次執行的未審稿預印本（Holmes-VAD），或悄悄用了影片級指標（Holmes-VAU 是 398 樣本上的影片級數字，跟所有幀級數字不同類）。

預先註冊目標未達成 (自己講，別等人挖)

研究計畫 (PRD) 事前設的門檻：UCF 最低 83% (目標 85–87) → 實得 82.5，差 0.5 點未達；XD 最低 80% (目標 82–85) → 實得 78.7，差 1.3 點未達。以「接受的未達標」如實回報，不事後改目標。另外 RTFM 復現門檻也 miss：XD-I3D 配置復現到 65.7 AP vs 官方 77.8——診斷已排除評估管線問題 (有獨立 sanity anchor)，差距定位在訓練側 (特徵維度、多尺度時間網路、batch size 不匹配)。

9. 限制總整理 (口委問「你的研究有什麼限制」時照這順序講)

1. 效能差距 + 未達預註冊目標 (上面那格) ——根源是凍結設計的刻意取捨。
2. 分數校準：25% 正常幀 >0.98 ，固定閾值部署會狂誤報；排序型指標掩蓋了這件事。解法 (事後校準/滑動窗警報) 不需重訓，列為未來工作。
3. XD 高容量骨幹的種子敏感：Giant std 2.8 AP，所以那個資料集上單種子數字不可信——論文的因應是一律報三種子。
4. TTA 範圍：transductive 協定、離散度代理會誤判壓縮、增益只在「單模態壞掉」的條件、策略搜尋與評分同一組條件。
5. 資料集與劣化的外推性：只有兩個資料集，劣化是合成的 (ImageNet-C 協定)；真實世界的相機老化、跨城市部署可能不同。結論範圍限定在暴力導向異常——骨架互補性大概正是在「人體動作主導」的類別最強，不應假設能轉移到外觀主導的異常。
6. UCF 輸入保真度：用的是 $64 \times 64 / 3\text{FPS}$ 幀重發布版，比別人管線的原始影片低畫質 (XD 不受影響)。
7. 骨架編碼器超出預訓練範圍：NTU 預訓練是短的室內單動作片段，UCF 一個片段等效 20 秒，把編碼器拉出了它的舒適圈——解讀骨架單獨結果時的誠實 caveat。

10. 口試快答集 (每題 30 秒版本)

Q1. 骨架單獨那麼弱 (68.8/40.8) · 為什麼還要加它？

因為它帶的是**正交資訊**——視覺語言模型是靜態圖文訓練的，編碼場景語意但不太編碼肢體動態，而暴力恰好是動作現象。證據是三角驗證：①8/8 組不輸、6 組嚴格贏 (sign test $p \approx 0.03$)；②增益集中在人體動作類別 (Shooting +1.05 最乾淨)；③gate 給它的權重隨輸入變化、不是關掉它。另外在劣化研究裡，骨架流是唯一在視覺崩潰時還活著的模態——沒有它就沒有第 6 章的路由方法。

Q2. 為什麼不微調骨幹？微調不就能追上 SOTA？

三個理由：24GB 單卡跑不動端到端影片級微調；凍結讓所有差異可歸因 (不會被微調軌跡污染)；凍結讓 $6 \times 4 \times 3 = 72$ 格的網格研究每格 5 分鐘就能跑完。這不是偷懶，是**論文刻意刻畫的 regime**：「一個可重現的單 GPU 凍結特徵系統能做到、和做不到什麼」。

Q3. TENT/SAR 沒效，會不會只是你超參數沒調好？

我們論證是結構性的：AUC 只在乎排序，對單調變換免疫；可動的只有 1,536 個 LayerNorm 仿射純量，而劣化偏移住在上游凍結特徵裡——這麼小的仿射修正無力重排池化分數。旁證：搬特徵統計的 NORM/CORAL「構得到」偏移所在空間，卻因破壞排序而失敗——問題不是構不構得到，是排序。誠實揭露：只跑參考學習率 $1e-3$ 沒掃 lr ，所以斷言依賴這個機制論證。另外我們修過兩個協定坑 (dropout 假增益、episodic 結構性失效)，修完後結果 bit-級可重現——這個 null 是下過功夫驗證的 null。

Q4. 你的 TTA 方法有沒有可調超參數？「2 倍」那個閾值不算嗎？

骨架閾的 2 倍錨點是先驗固定、不是對效能調的，而且實務上 s 飽和到 $\{0,1\}$ (重抽骨架的條件 $z \gg z_0$ 、重用快取的條件 $z \approx z_0$)，確切值不影響結果。整個方法零參數更新、零標籤， $w=1$ 時 bit-級還原原模型。

Q5. +13.2 那個數字是什麼？跟 +1.21 什麼關係？

四個聚合層級：+1.21 是 4 骨幹 20 條件總平均；+4.83 是高斯家族跨骨幹平均；+8.95 是 SO400M 的高斯家族平均；+13.2 是 SO400M 在高斯嚴重度 5 **單一格**——視覺流崩最慘的那格。報告時永遠先講 +1.21，再講峰值。

Q6. Transductive 是什麼意思？能實際部署嗎？

可靠度統計是把一個劣化條件的整批測試資料先池化計算的——這是劣化穩健性領域的標準評估協定，但不是線上部署配方。誠實的主張類別是「轉導式穩健性恢復」。好消息是路由訊號只是每條件兩個純量，串流估計應該很快收斂——列為未來工作，做完前不做 online 主張。

Q7. 為什麼 UCF 用 AUC、XD 用 AP？

遵循各基準的標準協定 (Sultani 2018 / Wu 2020)，確保與所有文獻可比。性質差異：AUC 只看排序、不受類別不平衡影響；AP 把權重壓在排名最前面的幀，對頂端排序的小變動更敏感——這也是 XD 種子變異較大的原因之一。

Q8. 排除 36 部短影片 (254/290) 會不會讓你的 UCF 數字不公平？

64 幀片段是骨架流的結構性最小單位。排除的是資料集裡最短的影片 (3FPS 下不到約 21 秒)，論文顯著揭露這點且所有配置一視同仁，所以內部比較完全公平；跟外部比較時我們也如實標注 cohort 是 254 部。XD 只排除 1 部，不受影響。

Q9. 你的頭條 82.5 可信度多高？

三個種子平均、固定切分、幀數 manifest committed 在 repo、可從 repo 重現。影片級 bootstrap 95% CI 是 [75.6, 88.0]——寬達 12 點，但這是 UCF 測試集只有 ~250 部影片的性质，所有在這個基準上報數的方法都繼承同樣的不確定度；XD 的 CI 窄一半，所以結論在 XD 上更穩。另外提交後又做了一次一致性重跑 (版本鎖定的乾淨程式碼重訓 29 格)，headline 在 82.5 重現 (-0.06 點)，所有定性結論不變。

Q10. 平滑項那個 footnote (兩種實作) 是怎麼回事？

早期實作把平滑懲罰誤加在 batch 軸 (相鄰影片) 而非時間軸 (相鄰片段)；釋出版已修正。seed-42 的 UCF 行與 headline 三種子是舊實作訓的。A/B 對照顯示修正只造成 -0.13 點；提交後的完整一致性重跑證實 headline 用正確實作重現於 82.5、結論全數保持。如實報告、不隱藏。

Q11. 這個系統能直接拿去實際部署嗎？

還不能，兩個誠實的缺口：①校準——四分之一正常幀分數 >0.98 ，固定閾值會狂誤報，需要事後校準或滑動窗排序警報 (都不需重訓骨幹)；②TTA 是轉導式的。但部署面的優勢是真的：可訓練頭 $<1M$ 參數、換新骨幹只要重抽特徵加幾分鐘訓練、路由機制失敗模式是「不動作」所以可以常開。

Q12. 未來工作最優先做什麼？

最大單一空間是**片段間時間建模**（輕量 TCN 或一層 transformer）——我們把對 CLIP-TSA 的殘餘差距歸因於此。已驗證但刻意不採納的：XD 測試分數 64 幀平滑 +0.57 AP——因為是結果凍結後發現的，採納會破壞論文主張的可重現紀律（未來預註冊窗口後採納）。其他：文字分支（VadCLIP 式）、骨架獨立頭的組合路由（估 +1-2 點）、串流版可靠度估計、XD 音訊第三流。

11. 必背數字小抄 (最後一眼)

項目	數字
UCF-Crime headline	$82.5 \pm 0.4 \% \text{ AUC}$ (Gated + SigLIP2 Giant · 3 種子)
XD-Violence headline	$78.7 \pm 0.9 \% \text{ AP}$ (Gated + SigLIP2 SO400M · 3 種子)
骨架單獨	68.8 AUC (UCF) / 40.8 AP (XD)
融合一致性	8/8 不輸、6/8 嚴格贏、平均 +0.6、sign test $p \approx 0.03$
Late fusion 慘況	UCF : CLIP 78.9 vs 純視覺 81.2 (-2.3) ; XD : 低 gated 10.9~13.0 點
可訓練參數 / 訓練時間	0.50M–1.02M / 每配置 <5 分鐘 (單張 RTX 4090)
種子 / 切分	42, 123, 2024 / 15% 分層驗證切分 (固定共用)
MIL 設定	T=32 包長、top-k k=3、margin 1、lr $1e-4$ 、 $\lambda_1=8e-3$ 、 $\lambda_2=8e-4$ (UCF) / 0 (XD)
劣化基準	UCF-Crime-C : 4 類型 $\times$ 5 嚴重度 = 20 條件 ; 未調適平均掉 ~20 點 (60.6)
TENT/SAR null	每骨幹 $ \Delta < 0.1$ 點 (最差 0.082) ; 可調面 = 1,536 個 LN 純量
CORAL 淘汰	LOCO 評分 -1.62、0/4 骨幹為正
disc_reweight	4/4 骨幹為正、12/12 格為正、平均 +1.21、高斯家族 +4.83、峰值 +13.2 (SO400M 高斯 sev5)
誤路由案例	SigLIP2 Base 單種子高斯 sev5 -3.2 (該骨幹平均仍 $+1.50 \pm 1.14$)
校準弱點	正常幀 75 百分位 = 0.986 ; 異常均值 0.874 vs 正常 0.382
Bootstrap CI	UCF [75.6, 88.0] (寬 12.4) ; XD [76.6, 82.7] (寬 6.1)
UCF 評估 cohort	254/290 部 (64 幀排除 ; XD 僅排 1 部)
公平區對照	RTFM 84.3/77.8、MGFN 87.0/79.2、UR-DMU 87.0/81.7、CLIP-TSA 87.6/82.2
SOTA 頂端 (不同 regime)	GS-MoE 91.6、PI-VAD 90.3、DSANet 89.4、VadCLIP 88.0
PRD 未達門檻	UCF 差 0.5 (門檻 83) ; XD 差 1.3 (門檻 80) ——如實接受

最後一句話 (結辯用)

「這本論文示範：骨架動態與視覺語言語意的結合、謹慎的骨幹選擇、以及對調適技術的誠實評估，能推進我們對實用弱監督暴力偵測系統的理解——而一個在透明限制下取得、讀者能夠信任並重現的結果，本身就是值得直白陳述的貢獻。」